RAG - Retrieval-Augmented Generation

Comparaison de services et options gratuites pour l'ingestion, la recherche vectorielle et la génération augmentée par récupération

1. Ce qu'est un système RAG

Un système RAG combine une source documentaire, un mécanisme de recherche et un modèle de langage. Les documents sont découpés en morceaux (chunks), transformés en vecteurs (embeddings), stockés dans un index vectoriel, puis les passages les plus pertinents sont récupérés au moment de la question et fournis au LLM.

Documents PDF, DOCX, SharePoint, Web	Extraction Docling / PyMuPDF / indexer	Chunking Découpage du contenu	Embeddings Texte -> vecteurs	Vector DB Qdrant / Azure AI Search / etc.	Retrieval Top passages pertinents	LLM Réponse fondée sur les sources

2. Services et solutions comparables

Solution	Type	Ingestion / vectorisation	Index vectoriel	Option gratuite	Intérêt principal	Pour votre formation
Azure AI Search	Service cloud géré	Très intégrée : indexers, skillsets, chunking et vectorisation intégrée	Oui	Oui, niveau gratuit limité	Entreprise Microsoft / Azure, RAG géré, intégration documentaire	Très utile après le pipeline manuel
Qdrant Cloud	Base vectorielle cloud	Ingestion à orchestrer ; embeddings possibles via services/modèles externes ou cloud	Oui	Oui, offre gratuite selon limites du fournisseur	Simple, rapide, très bon pour apprendre la recherche vectorielle	Excellent choix maintenant
Weaviate Cloud	Base vectorielle + fonctions RAG	Import et vectorisation plus intégrés selon configuration	Oui	Oui, offre gratuite selon limites du fournisseur	Bon compromis entre contrôle et automatisation	Bon comparatif après Qdrant
Pinecone	Base vectorielle managée	Ingestion et inférence de plus en plus intégrées ; Assistant pour cas RAG	Oui	Oui, plan gratuit / Starter selon conditions	Très simple à déployer, orienté SaaS	Utile pour comparaison cloud
Zilliz Cloud / Milvus	Base vectorielle cloud / open source	Pipeline généralement à construire autour de la base	Oui	Oui, offre gratuite limitée	Scalabilité et apprentissage des bases vectorielles	Secondaire pour l'instant
Qdrant local + Docling	Pile locale / open source	Manuelle : parsing, chunking, embeddings et insertion contrôlés en Python	Oui	Oui, open source	Comprendre chaque étape et garder les données localement	Meilleur choix pédagogique pour les 5 jours RAG

3. Différence importante : base vectorielle vs service RAG géré

Base vectorielle	Stocke les embeddings et retrouve les vecteurs proches. Exemple : Qdrant, Milvus, Pinecone. Le parsing des documents, le chunking et l'orchestration restent souvent à construire.
Service RAG géré	Automatise davantage la chaîne : connexion aux sources, extraction, chunking, embeddings, indexation et recherche. Azure AI Search est un bon exemple dans l'écosystème Microsoft.

4. Parcours recommandé pour votre formation

Maintenant : Docling / PyMuPDF -> chunking -> embeddings -> Qdrant -> retrieval -> LLM. Ensuite : refaire le même petit cas avec Azure AI Search pour voir ce que le cloud automatise. Puis : utiliser SharePoint comme source documentaire dans un scénario d'entreprise.

Note : les offres gratuites et leurs limites changent régulièrement. Vérifier les conditions du fournisseur au moment d'un projet réel. Cette fiche est destinée à l'apprentissage et à la comparaison d'architectures RAG.